

Instruction TTS / Binary Gender Evaluation

# Parler Mini / Large Constant Steering 2x

13,300-prompt bias evaluation per model

64-cell interaction analysis • 500-pair automated quality report

Lab meeting • 2026-08-31

# 本次實驗回答的問題

## Bias與binding

1. 相同的constant steering 2x能否跨Mini與Large降低global female skew？
2. career、persona、status與compositional prompts的變化是否一致？
3. 64個matched cells的interaction magnitude如何改變？

## 語音輸出

4. 500組paired samples的UTMOS與Whisper WER差異為何？
5. 平均差異是否集中於特定prompt stratum？
6. 哪些觀察仍需要人工聽測確認？


本次以觀察值與不確定區間為主，不將單一自動指標判定等同於主觀可感知品質。

# 共同實驗設定

| Item               | Parler Mini                               | Parler Large     |
|--------------------|-------------------------------------------|------------------|
| Model revision     | 0392b945...810d9                          | 50cb4b87...4f11e |
| Encoder width      | 1,024                                     | 1,536            |
| Method             | Female-to-male constant centroid steering | Same             |
| Strength           | 2x                                        | 2x               |
| Intervention point | Pooled final encoder representation       | Same             |
| Explicit prompts   | Regex bypass                              | Regex bypass     |
| Generation         | Batch 8, fixed prompts/seeds              | Same             |



Steering direction依checkpoint分別fit；統一的是演算法、anchor protocol與2x strength，不共用tensor。

# 完成規模與分析流程



| Component       | Mini            | Large           |
|-----------------|-----------------|-----------------|
| Bias evaluation | 13,300 / 13,300 | 13,300 / 13,300 |
| Quality pairs   | 500 / 500       | 500 / 500       |

# Global female rate往50%移動



Global rate是所有prompt sets的aggregate；是否存在axis-level cancellation需另外檢查。

# Axis-level female rate

| Prompt set | Mini Original | Mini 2x | Large Original | Large 2x |
|------------|---------------|---------|----------------|----------|
| Status     | 80.50%        | 52.50%  | 58.00%         | 30.00%   |
| Career     | 79.56%        | 60.70%  | 88.37%         | 72.48%   |
| Persona    | 77.05%        | 49.68%  | 85.58%         | 61.30%   |
| Two-axis   | 78.94%        | 59.59%  | 64.05%         | 40.23%   |
| Three-axis | 77.72%        | 57.62%  | 61.41%         | 33.62%   |
| Global     | 78.23%        | 56.26%  | 74.73%         | 51.37%   |

## Mini

五組female rate均降低；persona為49.68%，其他組仍偏female。

## Large

Career仍偏female；status與compositional prompts移向male側。

# Binding interaction magnitude

**-56.7%**

Mini mean |||

**11 → 0**

Mini strong cells

**-58.4%**

Large mean |||

**37 → 3**

Large strong cells

| Model | Original mean | Steering 2x mean | Moderate before | Moderate after | Not significant after |
|-------|---------------|------------------|-----------------|----------------|-----------------------|
| Mini  | 1.7151        | 0.7431           | 19              | 10             | 54 / 64               |
| Large | 3.2581        | 1.3546           | 13              | 20             | 41 / 64               |

兩模型皆呈現interaction attenuation；Large仍保留3個strong及20個moderate cells。

# Mini四個interaction families皆下降

| Family                    | Original mean | Mini 2x | Relative change |
|---------------------------|---------------|---------|-----------------|
| Career + persona          | 1.5072        | 0.8866  | -41.2%          |
| Status + career           | 1.9738        | 0.9528  | -51.7%          |
| Status + career + persona | 1.7386        | 0.6860  | -60.5%          |
| Status + persona          | 1.7777        | 0.4744  | -73.3%          |

## 共同方向

四個families的mean absolute interaction都較Original低。

## 剩餘結構

Mini 2x後沒有strong interaction，仍有10個moderate cells。



# 500-pair automated quality evaluation

**500**

pairs per model

**5 × 100**

fixed strata

**UTMOS**

speech-quality proxy

**WER**

intelligibility proxy

## Paired design

- Original與2x使用相同prompt IDs。
- 五組各100 pairs。
- 報告mean delta與95% bootstrap CI。

## 解讀方式

- 先呈現實際差值與分布。
- 分開查看每個stratum。
- 不將自動分數直接視為人耳判斷。

# Mini : global WER幾乎不變

## UTMOS

3.8507 → 3.8186

$\Delta$  -0.0321

95% CI [-0.0777, +0.0142]

## WER

0.1752 → 0.1750

$\Delta$  -0.0002

95% CI [-0.0185, +0.0184]

| Stratum    | UTMOS delta | WER delta |
|------------|-------------|-----------|
| Status     | -0.0935     | +0.0137   |
| Career     | +0.0278     | -0.0214   |
| Persona    | -0.0034     | -0.0094   |
| Two-axis   | -0.0985     | +0.0183   |
| Three-axis | +0.0070     | -0.0021   |

# Large：差異集中於部分strata

## UTMOS

3.5083 → 3.3919

$\Delta$  -0.1163

95% CI [-0.1916, -0.0397]

## WER

0.2931 → 0.3516

$\Delta$  +0.0586

95% CI [+0.0026, +0.1452]

| Stratum    | UTMOS delta | WER delta |
|------------|-------------|-----------|
| Status     | -0.1668     | +0.1843   |
| Career     | -0.1203     | +0.0275   |
| Persona    | -0.1689     | +0.0470   |
| Two-axis   | -0.1293     | +0.0381   |
| Three-axis | +0.0036     | -0.0040   |

# 自動品質數值的解讀範圍

## 目前可以直接報告

- Mini的global差值小，WER近似不變。
- Large的平均差值較Mini明顯。
- Large差異具有stratum heterogeneity。
- Three-axis在兩項Large指標上接近不變。

## 目前無法由自動指標回答

- 聽者是否能穩定辨認兩版本。
- 自然度差異是否具有實際影響。
- WER變化是否來自聲音、節奏或ASR模型。
- 第二個品質模型是否得到相同排序。

適合的下一個證據是blind paired listening與metric triangulation，而不是只增加同一指標的樣本數。

# 相同2x方法的跨模型觀察

| Observation         | Mini 2x            | Large 2x                |
|---------------------|--------------------|-------------------------|
| Global female rate  | 78.23% → 56.26%    | 74.73% → 51.37%         |
| Axis response       | 五組都降低；persona接近50% | 不同axis位移量差異較大           |
| Mean                | 1.7151 → 0.7431    | 3.2581 → 1.3546         |
| Strong interactions | 11 → 0             | 37 → 3                  |
| Automated quality   | Global差異小          | 平均差異較Mini明顯，且依stratum變化 |

相同演算法與strength在兩個模型都降低global skew與interaction magnitude，但模型與axis對steering的response不同。

# 目前觀察與後續工作

## 目前觀察

- Mini與Large的global female skew都降低。
- Mean interaction magnitude分別降低56.7%與58.4%。
- Mini的500-pair自動品質指標平均變化有限。
- Large的自動品質差異集中於部分strata。

## 後續工作

1. 五個strata的blind paired listening。
2. 較大型Whisper與第二個quality estimator。
3. 較低strength或axis-aware calibration。
4. 整理Mini RLACE-8與2x的paper ablation。

報告範圍：output-level calibration、interaction attenuation與automated quality observations；不延伸為representation erasure或uniform subgroup parity。