

Encoder Gender-Debiasing for Parler-TTS Mini

專案：ITTS_Debias / binding_effect | 模型：Parler-TTS Mini v1 | 硬體：RTX 4090 24GB | 日期：2026-08-11

狀態：主實驗 (test split, 1050 WAV) 已完成，H1-H5 全數通過驗證。LEACE 將職業刻板性別偏誤降低 **87%**，同時維持語音品質與 100% 顯式控制。Mixed-effects 統計尚未執行。

−87%

bias_gap 降幅
(0.389 → 0.049)

1050

主實驗 WAV
(5 methods × 210)

5/5

假設 H1-H5
全數成立

100%

顯式控制準確率
(leace_bypass)

1. 研究目標

在 Parler-TTS Mini 的文字描述 encoder 表徵上，以 **LEACE (Least-squares Concept Erasure)** 抹除性別方向，降低「職業刻板印象洩漏到合成語音性別」的偏誤，同時保留語音品質、語意保真度，以及顯式性別控制（明確要求 male/female 的 prompt 應 bypass 介入）。公平主指標並非要求 $P(\text{female})=0.5$ ，而是量測 social cue 相對 neutral baseline 造成的性別影響。

2. 方法概要

- 介入 **seam**：precompute encoder 最終投影狀態 → 套用 LEACE eraser → 以 `encoder_outputs` 傳入 `generate()`，不 patch Parler 內部。
- LEACE fit 標籤**：一律來自顯式性別 anchor；職業刻板性別只作分析 covariate，從不用於 fit（避免洩漏）。
- 探針：純 torch `LinearProbe` + ROC-AUC，不引入 scikit-learn。
- 五組對照**：`original`（基線）、`random`（rank-matched 隨機正交，null control）、`gender_direction`（rank-1 均值差投影）、`leace_nobypass`（無條件 LEACE）、`leace_bypass`（主方法：LEACE + 顯式 bypass）。後兩者共用同一 `artifacts/leace.pt`，僅差 bypass 旗標。

3. 資料與 split 設計

以 descriptor lemma 為單位切分，跨 split lemma 重疊 = 0，0 個 descriptor 含顯式性別詞。Grounded 職業性別先驗共 4M/5F，主實驗跑在 **test split (2M/3F)**，避免 pilot 時「女性職業僅 nanny 單一 lemma」造成檢定力不足。

主實驗 prompt set (`data/main.json`，210 prompts)

kind	數量	說明
grounded	125	女性 75 (midwife/receptionist/social worker 各 25)、男性 50 (butcher/fisherman 各 25)，跨 5 transcripts，無 persona 混淆
dev	50	dev-split implicit descriptors (漂移幅度量測)
neutral	15	無 descriptor 參考基線
anchor	20	顯式 male/female 控制 prompts

生成規模：210 prompts × 5 methods = 1050 WAV (約 4.4 小時，RTX 4090)。

4. 各階段進度

階段	內容	狀態
0-1	debias package、anchors/neutral/splits 資料基礎	✓ 完成
2	Encoder screening (separability / spillover / retention)，判定 GO	✓ 完成
3	LEACE 與對照組 eraser 擬合 (皆 rank-1、feat=1024)	✓ 完成
—	評估模型建置 (gender ONNX、UTMOS、whisper-tiny.en)，全離線	✓ 完成
4a	極小 smoke (28 prompts) 驗證 pipeline	✓ 完成
4b	標準 pilot (train split，700 WAV)	✓ 完成
5	主實驗 (test split，1050 WAV)	✓ 完成
6	Mixed-effects 統計	🕒 待執行
7	撰稿與復現包	🕒 待執行

測試：全套 49 tests 通過。

5. 主實驗結果 (test split，n=1050)

5.1 核心指標 — bias_gap

$$\text{bias_gap} = P(\text{female voice} \mid \text{女性刻板職業}) - P(\text{female voice} \mid \text{男性刻板職業})$$

不受各方法全域 neutral baseline 漂移影響 (女性 n=75、男性 n=50，10000 次 bootstrap)。

Method	bias_gap	95% CI	Δ gap vs original	顯著？
original	0.389	[0.261, 0.515]	—	—
random	0.407	[0.279, 0.540]	[-0.163, +0.200]	no
gender_direction	0.048	[-0.062, 0.159]	[-0.512, -0.169]	YES
leace_bypass	0.049	[-0.066, 0.168]	[-0.516, -0.164]	YES
leace_nobypass	0.030	[-0.083, 0.146]	[-0.530, -0.184]	YES

LEACE (bypass) 將 stereotype gap 從 0.389 降至 0.049 (-87%)， Δ gap 的 95% CI 完全不含 0。

5.2 品質、語意、顯式控制 (bootstrap 95% CI)

Method	UTMOS	WER	anchor control acc	neutral P(female)
original	3.778 [3.72, 3.83]	0.186 [0.16, 0.21]	0.850 [0.70, 1.00]	0.648
random	3.753 [3.69, 3.82]	0.213 [0.18, 0.24]	0.950 [0.85, 1.00]	0.659
gender_direction	3.785 [3.73, 3.84]	0.206 [0.18, 0.24]	0.950 [0.85, 1.00]	0.571
leace_bypass	3.834 [3.78, 3.88]	0.191 [0.16, 0.22]	1.000 [1.00, 1.00]	0.768
leace_nobypass	3.764 [3.70, 3.82]	0.232 [0.20, 0.26]	0.800 [0.60, 0.95]	0.633

6. 假設判讀

假設	結果	證據
H1：原始存在 bias	✓ 成立	original bias_gap = 0.389，CI [0.26, 0.52] 不含 0
H2：LEACE 消除 bias	✓ 顯著成立	leace_bypass gap 0.389 → 0.049 (-87%)， Δ gap CI 不含 0
H3：random 為 null control	✓ 成立	random gap 0.407 (未降低)， Δ gap CI 跨 0
H4：品質/語意保留	✓ 成立	UTMOS 3.75–3.83、WER 0.19–0.23，CI 全部重疊
H5：bypass 保留顯式控制	✓ 成立	anchor control：bypass 1.00 > nobypass 0.80

額外觀察：gender_direction (簡單均值差投影) 同樣顯著降低 gap (0.048)，顯示 rank-1 方向已捕捉大部分性別資訊；LEACE 的優勢在於同時維持最佳 UTMOS 與 100% 顯式控制。

7. 限制

- **顯式重建限制**：原始 checkpoint、原生成音檔與完整 13,300 prompts 不存在，本專案為 baseline 重建，不宣稱 exact reproduction。
- **grounded 職業性別不均** (test 2M/3F) 源自資料限制。
- **全域 baseline 漂移**：LEACE / gender-direction 會移動 neutral P(female) (leace_bypass 0.768)，故採用不受此漂移影響的 bias_gap 為主指標。

- **統計未完整**：mixed-effects 模型尚未執行，目前為 bootstrap 層級分析。

8. 下一步

1. **階段 6 — mixed-effects 統計**：`G ~ Method × Status × Career × Persona + (1|Descriptor) + (1|Template) + (1|Transcript) + (1|Seed)`
2. **階段 7 — 撰稿與復現包**：整理結果表格 / 圖表、方法與限制敘述、完整復現腳本。